

2025 年西南交通大学 数学建模校赛

题目：_____ C _____（填写 A / B / C ）

指导老师：_____ 无 _____（创新团队必须填写，其他组可填无 ）

	参赛队员 1	参赛队员 2	参赛队员 3
姓名	黄璨	刘紫博	
学号	2023112788	2023110724	
学院	交通运输与物流学 院	土木工程学院	
专业	交通运输	工程造价	
电话	18884337027	19855589981	
QQ	1965476034	2126565232	

西南交通大学教务处

西南交通大学实验室及设备管理处

西南交通大学数学建模创新实践基地

基于磁性材料损耗功率分析问题研究

摘 要

磁性材料广泛应用于电力和电子设备，但工作时会产生能量损耗，降低设备运行效率，增加维护成本。损耗功率受工作频率、磁通密度、电磁波形、工作温度及材料种类等多种因素影响，构建准确的数学模型对提升设备性能和降低能耗意义重大。

本次研究基于给定数据集，该数据集涵盖 4 种磁性材料在不同工况下的测量数据，包含温度、工作频率、损耗功率、电磁波形等参数，以及 1024 个磁通密度采样点。基于上述数据，需要解决多个关键问题：分析不同波形下磁通密度的变化特征，建立波形分类模型；考虑工作温度对传统损耗功率计算公式进行修正；分析电磁波形、材料、温度及其交互作用对损耗功率的影响，明确最低损耗的工况条件；改进模型使其适用于任意波形。这些研究成果将为磁性材料的优化应用和电力设备的节能设计提供支持。

针对问题一，对于磁通密度数据，首先采用 Python 算法检验表格是否存在缺失值，然后用**箱线图法**开展数据清洗工作，有效识别并处理了数据中的异常值，提升数据质量。随后，从经清洗的数据中，提取了十个具有代表性的统计特征与形状特征。此外，还运用了**主成分分析法（PCA）**进行降维处理。通过计算各主成分的贡献率，选取贡献率最大的两个主成分向量（达到 94%），作为新增的两个特征。最后，构建**决策树分类模型**，选取准确率最高的特征向量开展波形预测。模型评价上，对模型进行了多个维度的测验，其中准确率为 99.9%，评价模型具有良好性能。

针对问题二，正弦波损耗功率公式系数的求解，对经典公式两侧取对数，构建对数线性模型 $\ln(P) = \ln(k) + \alpha \cdot \ln(f) + \beta \cdot \ln(B_m)$ ，再运用 curve_fit 算法开展最小二乘拟合，通过最小化对数模型模拟值与损耗功率之间的残差平方和，获得修改前公式的最佳拟合系数。对公式进行温度修正时，考虑数据特征将 k 设定为温度 T 的函数 $k(T) = k_0 \cdot e^{T}$ 并固定其他参数，再次构建对数线性模型，再次用最小二乘法进行拟合求解，得到新模型的函数系数，并验证了这一假设的合理性。对四种材料重复上述过程，获得四种情况下公式的最优系数，详见图 2-8。误差分析过程中，求得原公式预测损耗功率的平均误差为 19.63%，而经优化后的模型，误差率降至 6.06%。

针对问题三，采用 spass 数据处理软件中的**三因素方差分析方法**，对电磁波形、磁性材料、工作温度包括它们的交互作用对损耗功率的影响的显著性进行分析。并构建**分层回归模型**分析它们之间的数量关系，具体分为温度控制层、磁芯材料层、电磁波形层，且模型 F 检验 $p < 0.001$ （显著水平），发现当满足工作温度为 90 度，磁性材料为材料 4，电磁波形是正弦波时，损耗功率能达到最小。

针对问题四，引用等效频率公式 $f_{eq} = \frac{1}{2\pi^2} \int_0^T \left(\frac{dB}{dt} \right)^2 dt$ 将非正弦波频率转化为等效正弦波频率，采用中心差分法（edge_order=2）计算每个采样点处磁通密度 B 的梯度，从而得到 $\frac{dB}{dt}$ 。边缘点采用二阶精度进行计算。将等效频率带入修改后的斯坦麦兹方程 $P = f \cdot (k_2 \cdot f_{sin,eq}^{\alpha_2-1} \cdot B_m^{\beta_2})$ 。同问题二构建线性回归模型，用最小二乘法以确定上述公式中相应的系数。最后误差分析此通用方程的误差为 12.20%

关键词:箱线图、主成分分析法（PCA）、决策树、方差分析、分层回归模型

一、问题重述

1.1 问题背景

在现代工业与电子技术中，磁性材料是变压器、电机、电感等电气设备的关键元件。设备运行时，磁性材料反复磁化产生损耗功率，引发能源浪费与设备发热。电力传输与分配环节，磁性材料损耗导致的能源损失占比显著，既降低能源利用效率，又增加发电成本与设备维护费用。在新能源领域，风力、光伏发电装机容量攀升，变流器、逆变器大量使用磁性材料的设备损耗功率问题突出，阻碍新能源高效利用与可持续发展。如何降低磁性材料损耗功率成为提升产品性能、拓展应用的关键因素。

1.2 问题重述

1.2.1 问题一

本题基于磁通密度采样数据，剖析三种电磁波形的特性，提取可有效区分它们的特征变量，构建恰当的分类模型，并对模型的合理性与有效性展开分析。

1.2.2 问题二

对于相同材料的正弦波形，传统损耗功率经验公式 $P = k \cdot f^\alpha \cdot B_m^\beta$ 未考虑工作温度。其中： P 为损耗功率； f 是频率； B_m 是磁通密度的峰值； k 、 α 、 β 是根据实验数据拟合的系数。本题要求考虑工作温度修正公式，给出修正前后 4 种材料的最佳拟合系数及平均相对百分比误差。

1.2.3 问题三

运用方差分析方法，探究电磁波形、磁性材料、工作温度三个因素及其交互作用对损耗功率的影响规律，确定在何种条件组合下，损耗功率可达到最小值。

1.2.4 问题四

问题 2 的模型通常仅适用于特定波形，但实际电磁波形多样，应用受限。需改进该模型，使其能适用于任意波形，并计算拟合公式的平均相对百分比误差，以此评估模型准确性。

二、问题分析

2.1 问题一的分析

针对问题一，磁通密度采样数据是问题分析的基础，首先需先对其进行预处理，包括检查填补缺失值、查找去除异常值等。观察数据的分布范围、变化趋势，分析不同波形下磁通密度随时间变化的规律，确保数据能准确反映电磁波形的真实特性。

其次对三种电磁波形的特点进行挖掘，从时域和频域剖析。比如正弦波，其磁通密度随时间呈现周期性的平滑变化，幅值固定；梯形波上升沿和下降沿通常是线性变化的，平顶段则保持一个相对稳定的高电平，低电平段保持稳定的低电平；三角波则是线性上升和下降，上升下降速率固定，通过这些特点可以初步区分波形。

基于波形特点提取特征。可考虑时域特征，如峰值、均值、方差，峰值能体现波形最大幅值，均值反映平均水平，方差体现数据离散程度；频域特征如基波频率、谐波含

量，不同波形的谐波分布不同；还可提取波形的上升时间、下降时间、占空比等，这些特征应能最大化区分三种波形，为分类提供依据。

接着选择合适的分类算法构建模型，如决策树，基于特征变量进行决策分支，易于理解和解释；支持向量机，能有效处理高维数据，寻找最优分类超平面；神经网络，具有强大的非线性拟合能力，可学习复杂的波形特征等。划分数据为训练集与测试集，训练模型并优化参数，让模型学习波形特征与类别间的映射关系，实现对波形的准确分类。

最后进行模型合理性和有效性分析。合理性分析主要看模型是否符合电磁波形分类的逻辑，特征变量选取是否合理，模型假设是否与实际情况相符。有效性分析则通过多种指标评估，如准确率、召回率、F1 值等，使用交叉验证方法，将数据集划分为训练集和测试集，在测试集上评估模型性能，观察模型对不同波形的分类准确性，借助混淆矩阵直观展示模型分类效果，判断模型有效性。

2.2 问题二的分析

针对问题二，为考虑工作温度对损耗功率经验公式的影响，决定引入温度修正函数对原始公式进行修正。在众多可能的温度修正函数形式中，线性函数和指数函数是较为常见的选择。线性函数形式相对简单，易于理解和计算，能在一定程度上反映温度与损耗功率的线性相关关系；指数函数则更适合描述温度对某些材料电磁特性具有指数级影响的情况。

首先要对四种材料的不同频率、磁通密度峰值、工作温度下的损耗功率数据进行整理。

接着代入数据，使用 `curve_fit` 函数对修正前后的公式中的系数分别进行拟合求解。该函数基于最小二乘法原理，通过不断调整模型中的参数，使得模型预测值与实验数据之间的误差平方和达到最小。这样得到的系数能够更准确地反映出在特定温度条件下磁芯损耗与其他因素之间的定量关系。

最后进行拟合平均相对百分比误差计算，通过对比修正前后的平均相对百分比误差评估温度修正公式对公式准确性的提升效果。

2.3 问题三的分析

针对问题三，在研究损耗功率时，需要探究电磁波形、磁性材料、工作温度这三个因素及其交互作用对损耗功率的影响。电磁波形的不同，如正弦波、方波、锯齿波等，会导致电磁感应过程中磁场的变化特性不同，进而影响电磁转换效率，最终对损耗功率产生作用。不同的磁性材料具有各异的磁导率、矫顽力等磁特性。高磁导率的材料更容易被磁化，能够更有效地传导磁场，但在反复磁化过程中，不同磁性材料产生的磁滞损耗不同；同时，材料的电导率也会影响涡流损耗。温度变化会影响磁性材料的微观结构和电磁特性。三种因素之间并非孤立地影响损耗功率，它们之间存在交互作用。因此，不仅要单独考虑每个因素对损耗功率的影响，更要研究它们之间的交互作用，才能全面掌握损耗功率的变化规律。

通过方差分析确定每个因素及其交互作用对损耗功率影响的显著性，通过分层回归模型确定各层次自变量对因变量的相对重要性，以及它们之间的交互作用情况，从而得出关于因变量影响因素的综合结论，找出最优组合。

2.4 问题四的分析

针对问题四，为修改第二问的公式使之对于所有波形都适用。首先使用等效频率公

式，基于磁通量密度随时间的变化情况来定义等效频率，即 $f_{eq} = \frac{1}{2\pi^2} \int_0^T \left(\frac{dB}{dt} \right)^2 dt$ ，将非正弦波形的变化转换为等效的正弦波参数。接着使用中心差分法对 $\frac{dB}{dt}$ 进行求解，边缘点采用二阶精度计算以提高准确性。后用等效正弦波频率计算非正弦波励磁下磁芯损耗并构用 curve_fit 建线性回归模型，求出相对应的系数，代入公式计算误差。

三、基本假设与符号说明

3.1 模型假设

在研究磁性材料损耗功率相关问题时，为了构建合理有效的模型，做出了如下假设：
假设数据完整可靠，数据中的异常值是由于随机因素导致的，而非数据本身的固有特性。

假设四种材料电磁特性稳定，在不同时间和条件下进行的数据测量和模型分析具有一致性和可比性。

假设等效频率公式能够准确地将非正弦波形的变化转换为等效的正弦波参数，且这种计算方法引入的误差在可接受范围内。

3.2 符号说明

符号	含义	单位
E_{SE}	原始损耗功率误差	无
E_{Mod}	修正损耗功率误差	无
f_{equal}	等效频率	Hz
B_{ij}	磁通密度数据	W/m^3
f_i	原始频率	Hz
B_m	最大磁通密度	W/m^3
P_j	原始损耗功率	W
u_j	磁通密度数据平均值	T
T_j	温度	℃
x_{max_j}	磁通密度最大值	无
x_{peak_j}	磁通密度峰值	无
$x_{peak_diff_j}$	磁通密度峰值差	无

四、模型一的建立与求解

4.1 数据预处理

4.1.1 缺失值处理

将四种材料整合成一个表格，并对整理后的数据进行清洗：使用 ISNULL 函数处理数据中可能出现的 NULL 值，NULL 值表示数据缺失或未定义，在查询数据时，若存在 NULL 值可能会影响结果的可读性，使用 ISNULL 函数可以将 NULL 值替换为合适的数值，让数据的显示和计算更符合需求，经检验，未发现缺失值。

4.1.2 异常值处理

使用箱线图快速呈现数据的中心位置、离散程度以及是否存在异常值，将数据升序

排列后，通过三个四分位数（ Q_1 , Q_2 , Q_3 ）将数据分为四等份， Q_1 为所有磁通密度的第一四分位数， Q_2 为磁通密度的中位数， Q_3 为第三四分位数。

$$\begin{cases} Q_1 = B_{25\%}, Q_3 = B_{75\%} \\ IQR = Q_3 - Q_1 \\ \text{异常值边界} = |Q_1 - 1.5IQR, Q_3 + 1.5IQR| \end{cases}$$

如图 1-1、图 1-2，上下须之外的为异常值，对其进行清理，由于数据量足够大，选择直接删除异常值。




图 1-1




图 1-2

4.1.3 数据整体分析

问题一要求通过磁通密度分类波形，现随机挑选三种不同的波形，并将不同波形绘制（图 1-3）。正弦波按正弦函数规律变化，波形连续平滑，无突变；三角波形状呈三角形，上升和下降过程线性，变化率恒定；梯形波似梯形，包含上升、平顶、下降和低平段。并对不同波形的数量进行统计（图 1-4）




图 1-3




图 1-4

4.2 特征的提取

4.2.1 常规特征的提取及合理性分析

首先对统计特征进行提取：计算波形的均值、标准差、最大值、最小值、峰值、峰值差，通过这些特征反映波形的幅值变化范围和离散程度；

其次对形状特征进行提取：提取上升沿斜率、下降沿斜率，以描述波形变化的快慢；计算过零次数，用于表征波形在一个周期内穿越零电平频率。

通过绘制不同波形的特征向量均值，用以挖掘这些特征的显著性（图 1-5, 图 1-6）。对比发现各个特征值在不同的波形的大小差异明显，具有合理性




图 1-5




图 1-6

计算各波形的均值：

$$u = \frac{1}{N} \sum_{i=1}^N x_i$$

计算各波形的标准差：

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - u)^2}$$

计算各波形的最大值最小值：

$$x_{\max} = \max(B_{ij}) \quad x_{\min} = \min(B_{ij})$$

计算各波形的峰值和峰值差：

$$x_{\text{peak}} = \max(|x_1|, |x_2|, \dots, |x_N|)$$

$$x_{\text{peak_diff}} = x_{\max} - x_{\min}$$

计算各波形的上升沿集合和下降沿集合：

$$\text{rising_slope} = \begin{cases} \frac{1}{|R|} \sum_{i \in R} (x_{i+1} - x_i), & \text{if } |R| > 0 \\ \text{Nan}, & \text{其他} \end{cases} \quad R = \{i | x_{i+1} - x_i > 0\}$$

$$\text{falling_slope} = \begin{cases} \frac{1}{|F|} \sum_{i \in F} (x_{i+1} - x_i), & \text{if } |F| > 0 \\ \text{Nan}, & \text{其他} \end{cases} \quad F = \{i | x_{i+1} - x_i < 0\}$$

计算各波形的零交叉次数：

$$Z = \{i | \text{sign}(x_{i+1}) \neq \text{sign}(x_i)\}$$

$$\text{zero_crossing_count} = |Z|$$


计算偏度：

$$\text{Skewness} = \frac{\frac{1}{N} \sum_{i=1}^N (x_i - u)^3}{\sigma^3}$$

4.2.2 主成分分析法提取特征向量

从附件数据的量级来看，原始数据具有很高的维度，这会增加计算成本和模型的复杂性，还可能导致过拟合。主成分分析（PCA）可以将高维数据投影到低维空间中，在保留数据主要信息的同时，大大降低数据的维度。使用主成分分析对数据进行降维。

主成分分析能够把众多有相关性的变量重新组合成相互无关的综合变量。一般流程如下：



对原始数据进行标准化处理，若样本观测矩阵为

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \cdots & \cdots & \cdots & \cdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix},$$

标准化公式为
$$x_{ij}^* = \frac{x_{ij} - \bar{x}_j}{\sqrt{\text{Var}(x_j)}} \quad (i=1,2,\cdots,n; j=1,2,\cdots,p)$$

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad \text{Var}(x_{ij}) = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2, \quad (j=1,2,3,\cdots,p)$$

假定原始数据标准化后仍用 X 表示，相关系数矩阵

$$R = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1p} \\ r_{21} & r_{22} & \cdots & r_{2p} \\ \cdots & \cdots & \cdots & \cdots \\ r_{n1} & r_{n2} & \cdots & r_{np} \end{bmatrix},$$

$$\text{其中 } r_{ij} = \frac{\text{Cov}(x_i, x_j)}{\sqrt{\text{Var}(x_i)}\sqrt{\text{Var}(x_j)}}, \quad r_{ij} = \frac{\sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{\sqrt{\sum_{k=1}^n (x_{ki} - \bar{x}_i)^2} \sqrt{\sum_{k=1}^n (x_{kj} - \bar{x}_j)^2}}$$

计算相关系数 R 的特征值 $(\lambda_1, \lambda_2, \cdots, \lambda_p)$ 和相应特征向量 $a_i = (a_{i1}, a_{i2}, \cdots, a_{ip})$ $(i=1,2,\cdots,p)$ 。贡献率 = $\frac{\lambda_i}{\sum_{l=1}^p \lambda_l}$ ，贡献率越大，主成分包含原始变量信息越强。

初步尝试将磁通密度降低十维，计算这十个特征向量的贡献率（图 1-7），分析发现前两个特征向量方差贡献度达到 94%，故选定为特征向量，记为 X_1 、 X_2 。




图 1-7

由下图 1-8、图 1-9、图 1-10 验证可得，PCA 处理获得的特征向量 X_1 能有效区分三种波形。相同过程可证明 X_2 的有效性。




图 1-8

图 1-9




图 1-10

4.2.3 总结特征向量

通过上述过程，我们获得了一定的特征向量并验证了它们与波形存在的关系。现整理获得的所有特征变量，为后续建立分类模型做准备。

$$\text{特征向量} = \begin{cases} \text{统计特征: } u, \sigma, x_{\max}, x_{\text{peak}}, \\ \text{形状特征: } \text{rising_slope}, \text{falling_slope}, \text{zero_crossing_count} \\ \text{PCA 特征向量: } X_1, X_2 \end{cases}$$

4.3 模型的建立及求解结果

4.3.1 决策树原理介绍

决策树(Decision Tree)是一种常用的数据分类方法,它具有类似流程图的树结构,其中每个内部节点表示在一个属性上的测试,每个分枝代表一个测试输出,而每个树叶节点代表类或类分布。

决策树归纳的基本算法是贪心算法,它以自顶向下递归的各个击破方式构造决策树。决策树在构造过程中需要选择内部节点,也就是对某个属性做测试。一般采用信息增益(Information Gain)度量或类似指标选择测试。通过这种方式选出的属性使得对结果划分中的样本分类所需的信息量最小,并反映划分的最小随机性或“不纯度”。

本文采用一种常见的决策树构造算法 C4.5,它利用信息增益率(Information Gain Ratio)作为节点选取标准。设 S 是 s 个数据样本的集合。假定类标号属性具有 m 个不同值,定义 m 个不同类 $C_i (i=1,2,\dots,m)$ 。设 s_i 是类 C_i 中的样本数。对一个给定的样本分类所需的期望信息由下式给出:

$$I(s_1, s_2, \dots, s_m) = - \sum_{i=1}^m p_i \log_2(p_i)$$

$$p_i = \frac{s_i}{s}$$

其中, p_i 是任意样本属于 C_i 的概率,并用 $\frac{s_i}{s}$ 估计。

设属性 A 具有 v 个不同值 $\{a_1, a_2, \dots, a_v\}$ 。可以用属性 A 将 S 划分为 v 个子集: 其中 $\{S_1, S_2, \dots, S_v\}$, S_j 包含 S 中这样一些样本, 它们在 A 上具有值 a_j 。如果 A 选做测试集属性(即最好的分裂属性), 则这些子集对应于由包含集合 S 的节点生长出来的分枝。设 s_{ij} 是子集 S_j 中类 C_i 的样本数。根据由 A 划分成子集的熵(Entropy)或期望信息由下式给出:

$$E(A) = \sum_{j=1}^v \frac{s_{1j} + \dots + s_{mj}}{s} I(s_{1j}, \dots, s_{mj})$$

项 $\frac{s_{1j} + \dots + s_{mj}}{s}$ 充当第 j 个子集的权, 并且等于子集(即 A 值为 a_j) 中的样本个数除以 S 中的样本总数。熵值越小, 子集划分的纯度越高。

在 A 上分枝将获得的编码信息是

$$\text{Gain} = I(s_1, s_2, \dots, s_m) - E(A)$$

信息增益率定义为

$$\text{GainRatio} = \frac{\text{Gain}(S, A)}{\text{SplitInfo}(S, A)}$$

其中

$$\text{SplitInfo}(S, A) = - \sum_{i=1}^c \frac{|S_i|}{|S|} \log_2 \frac{|S_i|}{|S|}$$

4.3.2 模型训练

建立以不同参数为特征向量的决策树模型，发现以 PCA 特征向量以及统计特征 σ ， $x_{\max}$ ， x_{peak} 为特征值的决策树模型效果较好。将预处理和特征提取后的数据集按照 70%、30% 比例划分为训练集和测试集。训练集用于训练模型，测试集用于评估模型的最终性能。划分过程中采用分层抽样的方法，确保每个子集都包含三种电磁波形的数据，且比例与原始数据集一致，保证数据分布的均衡性。

4.3.3 模型评估

本文采用了准确率，召回率，F1 值来反映模型的预测效果，多指标的采用避免了只关注单一指标而导致对模型性能评估不全面的问题。


用训练好的模型对测试集进行预测。计算模型的准确率，准确率= $\frac{\text{预测正确的样本数}}{\text{总样本数}} \times 100\%$ ，准确率越高，说明模型对样本进行分类时的正确程度越高。

计算召回率= $\frac{\text{真正例数}}{\text{真正例数} + \text{假反例数}} \times 100\%$ ，召回率越高，说明模型找到的正类样本越全面，对正类样本的捕捉能力越强。

计算 F1 值，即准确率和召回率的调和平均数， $F1 \text{ 值} = \frac{2 \times \text{准确率} \times \text{召回率}}{\text{准确率} + \text{召回率}}$ ，F1 值的取值范围在 0 到 1 之间，值越高代表模型性能越好。本文决策树模型的三项指标如下：

	precision	recall	f1-score	support
0	0.99	0.99	0.99	1207
1	0.99	0.99	0.99	1447
2	0.99	0.99	0.99	1066
accuracy			0.99	3720
macro avg	0.99	0.99	0.99	3720
weighted avg	0.99	0.99	0.99	3720

同时借助混淆矩阵直观展示模型分类效果，如图 1-11，以矩阵形式展示了模型预测结果与真实结果之间的关系，直观看出在各类别波形预测中正确值远远大于错误情况。并基于混淆矩阵构建 ROC 曲线，在二分类问题中，预测结果可分为真正例（TP）、假正例（FP）、真反例（TN）和假反例（FN）。通过不断改变分类器的阈值，计算不同阈值下的真正例率（TPR）和假正例率（FPR），以 FPR 为横坐标，TPR 为纵坐标绘制出的曲线就是 ROC 曲线。其中， $TPR = TP / (TP + FN)$ ，反映了分类器正确识别正例的能力； $FPR = FP / (FP + TN)$ ，表示分类器将反例错误识别为正例的概率。如图 1-12 可知，ROC 曲线非常靠近左上角，正确率高达 99% 以上。



五、模型二的建立与求解

5.1 模型假设

传统的损耗功率经验公式表达为： $P = k \cdot f^\alpha \cdot B_m^\beta$ 。在该公式中， P 为损耗功率； f 是频率； B_m 是磁通密度的峰值； k 、 α 、 β 是根据实验数据拟合的系数，它们综合反映了材料自身特性对损耗功率的影响。因该公式未涵盖工作温度这一重要环境因素，在实际应用中可能导致计算结果与真实情况存在偏差。为考虑工作温度 T 对其的影响，将 k 假设为温度修正函数 $k(T)$ ，同时保持 α 、 β 为常数。根据此磁性材料的物理特性和数据特征，选择指数函数温度修正函数形式，故将公式具体表示为

$$k(T) = k_0 \cdot e^{\gamma T}$$

其中， k_0 、 γ 是与温度相关的系数，它们的取值决定温度对损耗功率的影响的程度和方式。

5.2 模型建立

5.2.1 原始公式系数的拟合

对于原始公式 $P = k \cdot f^\alpha \cdot B_m^\beta$ ，对等式两边取对数，得到对数线性模型[1]：

$$\ln(P) = \ln(k) + \alpha \cdot \ln(f) + \beta \cdot \ln(B_m)$$

其中， k, α, β 为待求系数。

接着提取附件中所有温度对应的数据，如图 2-1 所示。

	温度	频率	磁芯损耗	峰值磁通密度
0	25	50030	1997.955250	0.028849
1	25	50020	2427.749830	0.031419
2	25	50020	3332.725760	0.035535
3	25	50020	4502.908007	0.040015
4	25	50030	6063.023248	0.045028
...	...	...	...	...
1062	90	316230	54682.608350	0.043611
1063	90	316230	71443.968180	0.049015
1064	90	316230	94691.425060	0.055368
1065	90	316230	123821.811900	0.062089
1066	90	316230	163722.346800	0.069838

1067 rows × 4 columns

图 2-1

接着本文运用非线性最小二乘法进行参数曲线拟合，旨在寻找一条与原始损耗功率数据集最为匹配的曲线，以揭示变量间的潜在函数关系。

非线性最小二乘法通过不断调整模型函数中的参数，让模型预测值与实际观测值之差的平方和最小化。即最小化数据点与函数值之间的差异。

将不同温度下的所有数据分别代入磁芯损耗经验计算公式，通过 `curve_fit` 函数对公式中的系数进行拟合求解，得到在不同温度下各自对应的最佳拟合系数。数据点足够多，能合理覆盖自变量的取值范围，保证了拟合结果的可靠性和泛化能力。选定 $\ln(k)$ 、 α 、 β 的初始值为 -10、1.5、2.5，拟合得到结果。

故经验公式修正前 4 种材料的最佳拟合系数： $k = 1.9198e^{-1}$ 、 $\alpha = 1.6059$ 、 $\beta = 2.5066$ 。

5.2.2 修正公式系数的拟合

将温度修正因子 $k(T)$ 融入原经验公式。大量的实验研究和实际应用案例表明，工作温度对磁芯损耗有着显著且不可忽视的影响。磁芯材料的微观结构和电磁特性会随着温度的变化而发生改变，进而导致磁芯损耗呈现出与温度相关的变化规律。由于不同温度条件下磁芯材料内部的物理过程存在差异，故拟合系数也会随之不同。因此提取不同温度对应的数据，代入公式 $\ln(P) = \ln(k) + \alpha \cdot \ln(f) + \beta \cdot \ln(B_m)$ ，使用 `curve_fit` 函数，固定 α 和 β ，仅对 $\ln(k)$ 进行拟合，得到不同温度下所对应的 $\ln(k)$ 。




图 2-2

绘制 $\ln(k)$ 与温度 T 的关系图，如图 2-2，经观察得 $\ln(k)$ 与温度 T 成线性关系，验证了原假设 $k(T) = k_0 \cdot e^{\gamma T}$ 成立。

对 $k(T) = k_0 \cdot e^{\gamma T}$ 等式两边同时取对数，得到对数线性模型：

$$\ln(k) = \ln(k_0) + \gamma \cdot T$$

将所有数据代入模型中，使用 `curve_fit` 函数进行曲线拟合，得到结果如图 2-3。

故经验公式修正后 4 种材料的最佳拟合系数： $k_0 = 3.8440e^{-1}$ 、 $\gamma = -0.0118$ 。

拟合得到的温度修正参数：

$$\ln(k_0) = -0.9561$$

$$k_0 = 3.8440e^{-01}$$

$$\gamma = -0.0118$$

5.3 误差分析对比

图2-3

建立平均相对百分比误差计算公式，

$$E_{SE} = \frac{|P_{core} - P_{pred_SE}|}{P_{core}} \times 100\%$$

修正后的方程平均相对百分比误差计算公式，

$$E_{Mod} = \frac{|P_{core} - P_{pred_Mod}|}{P_{core}} \times 100\%$$

得到平均误差分别为：修正前：19.63%、修正后：6.03%。得到预测结果与实际值对比分别如下图 2-4、图 2-5




图 2-4




图 2-5

从图中也能得出，修正前后预测损耗功率与原始值的离散程度进行对比，温度修正后的斯坦麦茨方程预测效果更好。

重复上述步骤，可以分别求得另外三种材料修正前后的最佳拟合系数以及拟合的平均相对百分比误差，总结如图 2-6：

	材料	k_global	alpha	beta	k0	gamma	修正前误差	修正后误差
0	材料一	0.074	1.718	2.517	0.139	-0.012	29.633%	16.031%
1	材料二	0.074	1.718	2.517	0.139	-0.012	33.680%	20.451%
2	材料三	0.298	1.614	2.525	0.537	-0.011	30.933%	18.734%
3	材料四	0.417	1.596	2.557	0.789	-0.011	28.775%	17.052%

图 2-6

六、模型三的建立与求解

6.1 方差分析

6.1.1 三因素方差分析原理及其模型建立

三因素方差分析[2]属于方差分析的一种，用于研究三个因素对观测变量的影响以及它们之间的交互作用。

三因素方差分析将总变异分解为不同来源的变异，包括三个因素各自的主效应、两两因素之间的交互效应以及三因素的交互效应，误差项。通过比较这些不同来源变异的大小，来判断各个因素以及它们的交互作用对观测变量是否有显著影响。

首先提出假设：针对每个因素的主效应和因素间的交互效应分别提出原假设和备择假设。原假设通常是各因素主效应为零，即该因素对观测变量无显著影响，以及各交互效应为零，即因素之间不存在显著的交互作用。在本题中原假设为：电磁波形、磁性材料、工作温度这三种因素对损耗功率无显著影响，它们的交互作用对损耗功率也无显著影响；备择假设则是相应的原假设不成立。

接着计算平方和：计算总平方和（SST）、各因素的平方和（SSA、SSB、SSC 分别对应因素 A 磁性材料、B 电磁波形、C 工作温度）、两两因素交互作用的平方和（SSAB 磁性材料*电磁波形、SSAC 电磁材料*工作温度、SSBC 电磁波形*电磁波形）、三因素交互作用的平方和（SSABC 电磁材料*电磁波形*工作温度）以及误差平方和（SSE）。

假设有 n 个观测值，因素 A 有 a 个水平，因素 B 有 b 个水平，因素 C 有 c 个水平，观测值用 y_{ijk} 表示，其中 $i=1, 2, \dots, a$; $j=1, 2, \dots, b$; $k=1, 2, \dots, c$ 。

$$\text{总平方和: } SST = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^c (y_{ijk} - \bar{y})^2, \text{ 其中 } \bar{y} = \frac{1}{abc} \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^c y_{ijk}$$

$$\text{因素 A 的平方和: } SSA = bc \sum_{i=1}^a (\bar{y}_{i**} - \bar{y})^2, \text{ 其中 } \bar{y}_{i**} = \frac{1}{bc} \sum_{j=1}^b \sum_{k=1}^c y_{ijk}$$

$$\text{因素 B 的平方和: } SSB = ac \sum_{j=1}^b (\bar{y}_{*j*} - \bar{y})^2, \text{ 其中 } \bar{y}_{*j*} = \frac{1}{ac} \sum_{i=1}^a \sum_{k=1}^c y_{ijk}$$

$$\text{因素 C 的平方和: } SSC = ab \sum_{k=1}^c (\bar{y}_{**k} - \bar{y})^2, \text{ 其中 } \bar{y}_{**k} = \frac{1}{ab} \sum_{i=1}^a \sum_{j=1}^b y_{ijk}$$

$$\text{因素 A 与因素 B 交互作用的平方和: } SSAB = c \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij*} - \bar{y}_{i**} - \bar{y}_{*j*} + \bar{y})^2, \text{ 其中}$$

$$\bar{y}_{ij*} = \frac{1}{c} \sum_{k=1}^c y_{ijk}$$

$$\text{因素 A 与因素 C 交互作用的平方和: } SSAC = b \sum_{i=1}^a \sum_{k=1}^c (\bar{y}_{i*k} - \bar{y}_{i**} - \bar{y}_{**k} + \bar{y})^2$$

$$\text{因素 B 与因素 C 交互作用的平方和: } SSBC = a \sum_{j=1}^b \sum_{k=1}^c (\bar{y}_{*jk} - \bar{y}_{*j*} - \bar{y}_{**k} + \bar{y})^2$$

因素 A、B、C 交互作用的平方和：

$$SSABC = \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^c (y_{ijk} - \bar{y}_{ij*} - \bar{y}_{i*k} - \bar{y}_{*jk} + \bar{y}_{i**} + \bar{y}_{*j*} + \bar{y}_{**k} - \bar{y})^2$$

误差平方和： $SSE = SST - SSA - SSB - SSC - SSAB - SSAC - SSBC - SSABC$
将各平方和除以相应的自由度，得到均方。

因素 A 的均方为 $MSA = \frac{SSA}{dfA}$ ，其中 dfA 是因素 A 的自由度。

因素 B 的均方为 $MSB = \frac{SSB}{dfB}$ ，其中 dfB 是因素 A 的自由度。

因素 C 的均方为 $MSC = \frac{SSC}{dfC}$ ，其中 dfC 是因素 A 的自由度。

因素 A 与因素 B 交互作用的均方为 $MSAB = \frac{SSAB}{dfAB}$ ，其中 $dfAB$ 是因素 A 的自由度。

因素 A 与因素 C 交互作用的均方为 $MSAC = \frac{SSAC}{dfAC}$ ，其中 $dfAC$ 是因素 A 的自由度。

因素 B 与因素 C 交互作用的均方为 $MSBC = \frac{SSBC}{dfBC}$ ，其中 $dfBC$ 是因素 A 的自由度。

因素 A、B、C 交互作用的均方为 $MSABC = \frac{SSABC}{dfABC}$ ，其中 $dfABC$ 是因素 A 的自由度。

误差均方为 $MSE = \frac{SSE}{dfE}$

分别计算各因素主效应和交互效应的 F 值。F 值 = $\frac{\text{各因素均方}}{\text{误差均方}}$

确定临界值与决策：根据给定的显著性水平和相应的自由度，查 F 分布表确定临界值。将计算得到的各 F 值与临界值比较，若 F 值大于临界值，则拒绝相应的原假设，认为该因素的主效应或交互效应显著；否则，接受原假设，认为该效应不显著。

6.1.2 方差分析结果研究

通过 spass 数据软件将已经整理好的有关电磁波形，磁芯材料，温度与损耗功率的数据集进行三因素方差分析，得到结果如下图3-1：

项	平方和	自由度	均方	F	P	R ²	调整R ²
截距	432558449697703.2	1	432558449697703.2	3311.252	0.000***	0.081	0.078
磁芯材料	34871529111256.695	3	11623843037085.564	88.981	0.000***		
电磁波形	75365416394758.44	2	37682708197379.22	288.463	0.000***		
温度	9055436749164.771	3	3018478916388.257	23.107	0.000***		
磁芯材料 * 电磁波形	12011787221611.979	6	2001964536935.33	15.325	0.000***		
磁芯材料 * 温度	392608720870.419	9	43623191207.824	0.334	0.964		
电磁波形 * 温度	1515146031402.543	6	252524338567.091	1.933	0.072*		
磁芯材料 * 电磁波形 * 温度	855221657412.995	18	47512314300.722	0.364	0.993		
误差	1613577751128628.8	12352	130632913789.559		NaN		

图 3-1

对于变量磁芯材料，从 F 检验的结果分析可以得到，显著性 P 值为 0.000***，水平上呈现显著性，对损耗功率有显著性影响，存在主效应。

对于变量电磁波形,从F检验的结果分析可以得到,显著性P值为0.000***,水平上呈现显著性,对损耗功率有显著性影响,存在主效应。

对于变量温度,从F检验的结果分析可以得到,显著性P值为0.000***,水平上呈现显著性,对损耗功率有显著性影响,存在主效应。

对于变量磁芯材料 * 电磁波形,从F检验的结果分析可以得到,显著性P值为0.000***,水平上呈现显著性,对损耗功率有显著性影响,存在主效应。

对于变量磁芯材料 * 温度,从F检验的结果分析可以得到,显著性P值为0.964,水平上不呈现显著性,对损耗功率没有显著性影响,不存在主效应。

对于变量电磁波形 * 温度,从F检验的结果分析可以得到,显著性P值为0.072*,水平上不呈现显著性,对损耗功率没有显著性影响,不存在主效应。

对于变量磁芯材料 * 电磁波形 * 温度,从F检验的结果分析可以得到,显著性P值为0.993,水平上不呈现显著性,对损耗功率没有显著性影响,不存在主效应。

电磁波形、磁性材料、工作温度这三种因素及其交互作用对损耗功率的影响总结如下图3-2:

研究对象	对损耗功率是否有显著性影响
磁芯材料	是
电磁波形	是
温度	是
磁芯材料 * 电磁波形	是
磁芯材料 * 温度	否
电磁波形 * 温度	否
磁芯材料 * 电磁波形 * 温度	否

图 3-2

6.2 分层回归模型

6.2.1 分层回归模型的原理及其建立

为了进一步确定电磁波形、磁芯材料、工作温度这三种因素与损耗功率的具体影响程度,以便确立限制条件使损耗功率最小,本文构建了分层回归模型。

分层回归模型[3]将自变量按照一定的逻辑顺序或理论依据分为不同的层次,然后依次将各层次的自变量纳入回归方程进行分析。通过这种方式,可以逐步考察不同层次自变量对因变量的独特解释力,以及控制其他变量后,特定层次变量的影响。

首先将自变量分为不同层次:温度控制层、磁芯材料层、电磁波形层。接着建立基础模型,先将第一层自变量纳入回归模型,得到基础模型,分析这些变量对因变量的初步影响,计算相关统计量:决定系数 R^2 、 ΔR^2 、 F 、 ΔF 。后逐步加入层次变量,每次加入后重新估计模型参数,观察新加入变量的回归系数是否显著,以及的 R^2 变化情况。最后进行模型评估与比较,使用F检验来比较不同层次模型的拟合优度,判断加入某一层变量后模型是否有显著改进。分析回归系数的符号、大小和显著性,以理解各变量对因变量的影响方向和程度。具体结果如图3-3

分层回归												
	控制层				层次1				层次2			
	B	标准差	t	P	B	标准差	t	P	B	标准差	t	P
常数	236659.657	6594.014	35.89	0.000***	216960.536	8521.638	25.46	0.000***	276156.362	9166.041	30.128	0.000***
温度_50度	-34484.534	9456.555	-3.647	0.000***	-33292.756	9347.591	-3.562	0.000***	-36854.756	9136.633	-4.034	0.000***
温度_70度	-58053.415	9488.571	-6.118	0.000***	-56374.646	9379.346	-6.011	0.000***	-61205.861	9170.248	-6.674	0.000***
温度_90度	-60693.587	9467.677	-6.411	0.000***	-59217.401	9359.008	-6.327	0.000***	-64542.889	9152	-7.052	0.000***
磁芯材料_材料2					53536.789	9299.664	5.757	0.000***	62566.265	9101.453	6.874	0.000***
磁芯材料_材料3					83821.229	9143.561	9.167	0.000***	84564.412	8955.133	9.443	0.000***
磁芯材料_材料4					-70652.093	9473.32	-7.458	0.000***	-71271.403	9294.065	-7.668	0.000***
电磁波形_梯形波									-6474.9	8202.351	-0.789	0.430
电磁波形_正弦波									-172153.541	7718.311	-22.305	0.000***
R ²	0.004				0.027				0.072			
调整R ²	0.004				0.027				0.071			
F	F(3, 12400) = 17.755, P=0.000***				F(6, 12399) = 58.374, P=0.000***				F(8, 12398) = 120.255, P=0.000***			
ΔR ²	0.004				0.023				0.045			
ΔF值	F(3, 12400) = 17.755, P=0.000***				F(3, 12399) = 98.572, P=0.000***				F(2, 12398) = 297.519, P=0.000***			
因变量 (Y) : 损耗功率												

注：***、**、*分别代表1%、5%、10%的显著性水平

图 3-3

分层回归分析结果显示，模型通过逐步引入解释变量有效提升了拟合优度。控制层（仅温度变量）解释损耗功率变异的 0.4%（ $R^2=0.004$ ），所有温度水平均呈现显著负向效应（50 度： $B=-34484.534$ ， $p<0.001$ ；70 度： $B=-58053.415$ ， $p<0.001$ ；90 度： $B=-60693.587$ ， $p<0.001$ ），表明温度升高显著降低损耗功率。

层次 1 引入磁芯材料变量后，模型解释力提升至 2.7%（ $\Delta R^2=0.023$ ， $F=98.572$ ， $p<0.001$ ），材料 2（ $B=53536.789$ ， $p<0.001$ ）和材料 3（ $B=83821.229$ ， $p<0.001$ ）具有显著正向效应，材料 4 则呈显著负向效应（ $B=-70652.093$ ， $p<0.001$ ）。

层次 2 加入电磁波形变量后，模型解释方差进一步提高至 7.2%（ $\Delta R^2=0.045$ ， $F=297.519$ ， $p<0.001$ ），正弦波表现出极强的负向效应（ $B=-172153.541$ ， $p<0.001$ ），而梯形波效应不显著（ $B=-6474.9$ ， $p=0.430$ ）。所有模型 F 检验均达显著水平（ $p<0.001$ ），显示各层次模型整体有效。

值得注意的是，温度变量的系数估计在三个模型中保持稳定（如 50 度系数波动范围仅-34484 至-36854），表明核心结论具有稳健性。调整 R^2 与原始 R^2 接近，暗示模型未过度拟合。最终模型包含的 8 个预测变量共解释损耗功率 7.1%的变异量，其中电磁波形变量的引入带来最大边际贡献。

6.2.2 工作条件的选择

- （1）工作温度：选择 90℃
温度_90 度的系数（B 值）在所有温度中绝对值最大（-60,693.587 至-64,542.889），且显著（ $P=0.000***$ ），表明其对降低损耗功率的负向影响最强。
- （2）磁性材料：选择 材料 4
材料 4 的系数（B 值）为负（-71,271.403），且显著（ $P=0.000***$ ），表明其相比基准材料能显著减少损耗功率。
- （3）电磁波形：选择 正弦波
正弦波的系数（B 值）为负（-172,153.541），且显著（ $P=0.000***$ ），表明其对降低损耗功率的作用极强。而排腔波的效应不显著（ $P=0.430$ ），无需考虑。

七、模型四的建立与求解

7.1 模型建立

7.1.1 等效频率的引用

等效频率用一个单一的频率值来代表原本复杂的频率相关特性，把复杂问题转化为相对简单的、基于单一频率的问题来处理。为将非正弦波的变化转换为等效的正弦波参数，使用等效频率公式：

$$f_{eq} = \frac{1}{2\pi^2} \int_0^T \left(\frac{dB}{dt} \right)^2 dt$$

其中， $\frac{dB}{dt}$ 是磁通量密度对时间的变化率，即磁通量密度随时间变化的快慢程度。

对磁通量密度变化率进行平方运算： $\left(\frac{dB}{dt} \right)^2$ ，消除变化率的正负差异，只关注变化的幅度大小，更好地反映出磁通量密度变化在整个过程中的累积效应。并在一个完整的周期 T 内，对 $\left(\frac{dB}{dt} \right)^2$ 进行积分。周期 T 指的是磁通量密度变化完成一次完整循环所需要的时间。通过积分，将在整个周期内磁通量密度变化率的平方的所有信息累加起来，得到一个能够综合反映整个周期内磁通量密度变化特性的数值。系数 $\frac{1}{2\pi^2}$ 让最终得到的数值具有合适的量纲和物理意义，使其成为一个可以合理代表等效频率的量。

在此公式中，基于磁通量密度随时间的变化情况来定义等效频率的。磁通量密度的变化往往与电磁系统中的能量转换、信号传输等过程紧密相连。通过这个等效频率，可以把一个原本可能包含复杂磁通量变化的电磁系统，近似看作是一个具有特定频率（即等效频率 f_{eq} ）的简单系统来进行分析。大大简化分析过程。

对于正弦波，等效频率退化为实际频率 f ，与传统斯坦麦茨方程一致。

7.1.2 中心差分法


中心差分法是一种数值计算方法，优点是具有较高的精度，

在公式 $f_{eq} = \frac{1}{2\pi^2} \int_0^T \left(\frac{dB}{dt} \right)^2 dt$ 中，需先计算 $\frac{dB}{dt}$ 。当磁通量密度 B 是通过离散采样点获得的数据时，可以使用中心差分法来近似计算 $\frac{dB}{dt}$ 。

对于中间的采样点 i ($1 \leq i \leq n-1$ ，不包括起始点 $i = 0$ 和终点 $i = n$ ，它们不能用标准的中心差分形式计算)。用 B 在 t_{i+1} 和 t_{i-1} 这两个相邻点的值来近似 t_i 点处的变化率。具体公式为： $\left(\frac{dB}{dt} \right)_i \approx \frac{B_{i+1} - B_{i-1}}{2\Delta t}$

对于起始点 $i = 0$ ，由于没有 t_{-1} 对应的 B_{-1} 值，不能用中心差分公式，通常可以采用向前差分法，即 $\left(\frac{dB}{dt} \right)_0 \approx \frac{B_1 - B_0}{\Delta t}$ ；对于终点 $i = n$ ，没有 t_{n+1} 对应的 B_{n+1} 值，一般采用向后差分法，即 $\left(\frac{dB}{dt} \right)_n \approx \frac{B_n - B_{n+1}}{\Delta t}$ 。

边缘点则采用二阶精度计算以提高准确性。最后计算出相对应的等效频率如图：



7.1.3 公式改进与误差分析

用前文获得的等效正弦波频率计算非正弦波励磁下磁芯损耗：

$$P = f \cdot (k_2 \cdot f_{\sin.eq}^{\alpha_2-1} \cdot B_m^{\beta_2}) [4],$$

其中， f 是非正弦波频率； k_2 、 α_2 、 β_2 是等效频率下斯坦麦茨方程的系数

并同问题二建模过程，使用最小二乘法对对数线性方程进行参数曲线拟合，求出相对应的系数：

拟合得到的全局参数：


$$\ln(k_{\text{global}}) = -2.7448$$

$$k_{\text{global}} = 6.4262e-02$$

$$\alpha = 0.7260$$

$$\beta = 2.4024$$

把得到的相关系数带进计算并计算误差，得出平均误差为 22.204%，与实际值进行对比



八、模型的评价与推广

8.1 模型的评价

模型具有以下优点：

适用性广：通过在原损耗功率计算公式中添加温度函数，并引进等效频率转换公式，该模型能够很好的预测大部分情况下磁性材料的损耗功率。

准确性：通过将传统特征与 PCA 降维特征进行结合训练，并取其中效果好的作为特

征向量，大幅提升了该模型预测波形的准确性。

同时也有一些不足，模型具有一定的局限性，模型可能不适用于高频谐波丰富的波形。在解决这类问题时，要考虑高频成分对损耗的影响。

8.2 模型的改进

等效频率公式的合理性和准确性依赖于对磁通量密度变化率的准确计算和理解，实际应用中可能受到测量误差、电磁干扰等因素影响，导致等效频率计算存在偏差。

8.3 模型的推广

模型不仅完成了波形的辨别，多种因素对损耗功率的影响及复杂情况下损耗功率的计算，还可以用于电力电子设计：优化高频变压器和电感器的磁芯选型。

九、参考文献

[1]Severns, R. (1991). HF core loss for non - sinsoidal waveforms. In Proc. HFPC' 91 (pp. 140 - 148).

[2] 郭萍. 三因素方差分析的原理及应用[J]. 沈阳大学学报(自然科学版), 2015, 27(1):40 - 43.

[3] 聂洪涛, 韩欣悦. 我国有效专利区域发展“马太效应”困境及其调适——基于分层回归的实证研究[J]. 经济论坛, 2025. 3. 30

十、附录

第一问：

```
#!/usr/bin/env python
# coding: utf-8
import pandas as pd
data1=pd.read_excel('C 题附件.xlsx',sheet_name='材料 1')
data2=pd.read_excel('C 题附件.xlsx',sheet_name='材料 2')
data3=pd.read_excel('C 题附件.xlsx',sheet_name='材料 3')
data4=pd.read_excel('C 题附件.xlsx',sheet_name='材料 4')

data1.head()
data1.insert(0, '磁芯材料', '材料 1')
data2.insert(0, '磁芯材料', '材料 2')
data3.insert(0, '磁芯材料', '材料 3')
data4.insert(0, '磁芯材料', '材料 4')

data=pd.concat([data1,data2,data3,data4])

data.to_csv('data.csv',index=None)

# In[279]:

import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, recall_score, f1_score,
confusion_matrix, classification_report, roc_curve, auc
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier,
GradientBoostingClassifier
import xgboost as xgb
import matplotlib.pyplot as plt
from sklearn.preprocessing import label_binarize
from sklearn.multiclass import OneVsRestClassifier
from sklearn.metrics import roc_auc_score
import seaborn as sns

import matplotlib.pyplot as plt
```

```

import seaborn as sns
import numpy as np
from sklearn.decomposition import PCA
X=data[data.columns[5:]]
X.columns = X.columns.astype(str)
pca = PCA(n_components=2)
pca.fit(X)
newX=pca.fit_transform(X)

```

```
# In[280]:
```

```

data.insert(5, 'X1', newX[:,0])
data.insert(6, 'X2', newX[:,1])

```

```

def extract_waveform_features(data):
    """

```

```

    从磁通密度数据中提取均值、标准差、最大值、最小值、峰值和峰值差
    :param data: 磁通密度数据，一维数组
    :return: 包含特征的字典
    """

```

```

    # 计算均值
    mean_value = np.mean(data)
    # 计算标准差
    std_value = np.std(data)
    # 计算最大值
    max_value = np.max(data)
    # 计算最小值
    min_value = np.min(data)
    # 计算峰值（这里假设峰值是绝对值最大的值）
    peak_value = np.max(np.abs(data))
    # 计算峰值差
    peak_difference = max_value - min_value

```

```

    # 形状特征
    rising_edges = np.where(np.diff(data) > 0)[0]
    falling_edges = np.where(np.diff(data) < 0)[0]

```

```

    if len(rising_edges) > 0:
        rising_slope = np.mean(np.diff(data[rising_edges])) /
np.diff(rising_edges))
    else:

```



```

    rising_slope = np.nan

    if len(falling_edges) > 0:
        falling_slope = np.mean(np.diff(data[falling_edges]) /
np.diff(falling_edges))
    else:
        falling_slope = np.nan

    zero_crossings = np.where(np.diff(np.sign(data)))[0]
    zero_crossing_count = len(zero_crossings)

    skewness = skew(data)

    features = {
        'mean': mean_value,
        'std': std_value,
        'max': max_value,
        'min': min_value,
        'peak': peak_value,
        'peak_difference': peak_difference,
        'rising_slope': rising_slope,
        'falling_slope': falling_slope,
        'zero_crossing_count': zero_crossing_count,
        'skewness': skewness,
    }
    return features

```

```

import numpy as np
subset = data.iloc[:, 5:]

```

In[283]:

```

mean_list = []
std_list = []
max_list = []
min_list = []
peak_list = []
peak_difference_list = []
rising_slope_list = []
falling_slope_list = []
zero_crossing_count_list = []
skewness_list = []

```

```

# 遍历每一行的磁通密度数据，提取特征
for _, row in subset.iterrows():
    features = extract_waveform_features(row.values)
    mean_list.append(features['mean'])
    std_list.append(features['std'])
    max_list.append(features['max'])
    min_list.append(features['min'])
    peak_list.append(features['peak'])
    peak_difference_list.append(features['peak_difference'])
    rising_slope_list.append(features['rising_slope'])
    falling_slope_list.append(features['falling_slope'])
    zero_crossing_count_list.append(features['zero_crossing_count'])
    skewness_list.append(features['skewness'])

data.insert(7, 'mean', mean_list)
data.insert(8, 'std', std_list)
data.insert(9, 'max', max_list)
data.insert(10, 'min', min_list)
data.insert(11, 'peak', peak_list)
data.insert(12, 'peak_difference', peak_difference_list)
data.insert(13, 'rising_slope', rising_slope_list)
data.insert(14, 'falling_slope', falling_slope_list)
data.insert(15, 'zero_crossing_count', zero_crossing_count_list)
data.insert(15, 'skewness', skewness_list)

data

# In[314]:

import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import skew

# 假设这是你的数据集，这里简单生成一个示例数据集
import numpy as np
columns = ['电磁波形', 'max', 'min', 'peak',
           'zero_crossing_count', 'skewness', 'peak_difference', 'std']
data1=data[columns]

```

```

plt.rcParams['font.sans-serif']=['SimHei'] # 中文支持
plt.rcParams['axes.unicode_minus']=False
plt.rcParams.update({'font.size': 18})

# 计算不同波形的特征向量平均值
grouped = data1.groupby('电磁波形').mean()

# 绘制柱状图对比不同波形的特征向量平均值
features = grouped.columns
num_features = len(features)
num_wave_types = len(grouped.index)

x = range(num_features)
width = 0.8 / num_wave_types

fig, ax = plt.subplots(figsize=(12, 6))
for i, wave_type in enumerate(grouped.index):
    values = grouped.loc[wave_type].values
    ax.bar([pos + i * width for pos in x], values, width, label=wave_type)

ax.set_xticks([pos + width * (num_wave_types - 1) / 2 for pos in x])
ax.set_xticklabels(features, rotation=45)
ax.set_title('不同波形的特征向量的比较')
ax.set_ylabel('平均值')
ax.legend()

# 调整纵坐标范围
min_value = grouped.min().min()
max_value = grouped.max().max()
padding = (max_value - min_value) * 0.1 # 添加一些 padding 以确保柱子不紧贴坐标轴
ax.set_ylim(min_value - padding, max_value + padding)

plt.show()

# In[317]:

import pandas as pd
import seaborn as sns

```

```

import matplotlib.pyplot as plt
from scipy.stats import skew

import numpy as np
columns = ['电磁波形', 'falling_slope', 'mean',
          'rising_slope']
data2=data[columns]

# In[318]:

plt.rcParams['font.sans-serif']=['SimHei'] # 中文支持
plt.rcParams['axes.unicode_minus']=False
plt.rcParams.update({'font.size': 18})

# 计算不同波形的特征向量平均值
grouped = data2.groupby('电磁波形').mean()

# 绘制柱状图对比不同波形的特征向量平均值
features = grouped.columns
num_features = len(features)
num_wave_types = len(grouped.index)

x = range(num_features)
width = 0.8 / num_wave_types

fig, ax = plt.subplots(figsize=(12, 6))
for i, wave_type in enumerate(grouped.index):
    values = grouped.loc[wave_type].values
    ax.bar([pos + i * width for pos in x], values, width, label=wave_type)

ax.set_xticks([pos + width * (num_wave_types - 1) / 2 for pos in x])
ax.set_xticklabels(features, rotation=45)
ax.set_title('不同波形的特征向量的比较')
ax.set_ylabel('平均值')
ax.legend()

# 调整纵坐标范围
min_value = grouped.min().min()
max_value = grouped.max().max()
padding = (max_value - min_value) * 0.1 # 添加一些 padding 以确保柱子不紧贴坐标轴
ax.set_ylim(min_value - padding, max_value + padding)

```

```
plt.show()
```

```
# In[319]:
```

```
# import numpy as np
# import pandas as pd
# from scipy.stats import skew

# def extract_features(flux_density):
#     """
#     从磁通密度数据中提取特征
#     :param flux_density: 一维磁通密度数组
#     :return: 包含特征的数组
#     """
#     # 统计特征
#     mean_value = np.mean(flux_density)
#     std_value = np.std(flux_density)
#     max_value = np.max(flux_density)
#     min_value = np.min(flux_density)
#     peak_value = np.max(np.abs(flux_density))
#     peak_difference = max_value - min_value

#     # 形状特征
#     rising_edges = np.where(np.diff(flux_density) > 0)[0]
#     falling_edges = np.where(np.diff(flux_density) < 0)[0]

#     if len(rising_edges) > 0:
#         rising_slope = np.mean(np.diff(flux_density[rising_edges]) /
# np.diff(rising_edges))
#     else:
#         rising_slope = np.nan

#     if len(falling_edges) > 0:
#         falling_slope = np.mean(np.diff(flux_density[falling_edges]) /
# np.diff(falling_edges))
#     else:
#         falling_slope = np.nan

#     zero_crossings = np.where(np.diff(np.sign(flux_density)))[0]
#     zero_crossing_count = len(zero_crossings)
```

```

# # 偏度
# skewness = skew(flux_density)

# return np.array([mean_value, std_value, max_value, min_value,
peak_value,
# peak_difference, rising_slope, falling_slope,
# zero_crossing_count, skewness])

# def extract_features_from_dataset(data):
# """
# 从数据集提取磁通密度特征
# :param data: 数据集，每一行代表一个波，第 5 - 1029 列是磁通密度
# :return: 特征矩阵，每一行是一个波的特征向量
# """
# features_list = []
# for row in data.values:
#     flux_density = row[7:1030]
#     features = extract_features(flux_density)
#     features_list.append(features)
# return np.array(features_list)

# # 示例数据读取，假设数据存储在 CSV 文件中

# # 提取特征向量
# feature_matrix = extract_features_from_dataset(data)

# # 输出特征矩阵的形状
# print("特征矩阵形状:", feature_matrix.shape)

feature_columns = [ 'mean', 'std', 'max', 'peak',
'peak_difference', 'rising_slope', 'falling_slope', 'zero_crossing_count', 'skewness' ]

data['电磁波形']=data['电磁波形'].map({'正弦波': 0, '三角波': 1, '梯形波': 2})

pd.get_dummies(data['磁芯材料'])

```

```

from collections import Counter
Y = data['电磁波形'].copy()

from collections import Counter
Counter(Y)

X = data[feature_columns]
    # 划分训练集和测试集
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3,
random_state=42)
    # 创建决策树分类器模型
model = DecisionTreeClassifier(random_state=42)
    # 训练模型
model.fit(X_train, Y_train)
    # 计算 F1 分数

# import pandas as pd
# from sklearn.model_selection import train_test_split
# from sklearn.ensemble import RandomForestClassifier
# from sklearn.metrics import f1_score

# # 假设 data 是你的 DataFrame 数据
# # 假设 Y 是你的目标变量
# # 假设 feature_columns 是你选择的特征列

# # 选取特征变量
# X = data[feature_columns]

# # 划分训练集和测试集
# X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3,
random_state=42)

# # 创建随机森林分类器模型
# model = RandomForestClassifier(random_state=42)

# # 训练模型
# model.fit(X_train, Y_train)

# # 计算 F1 分数
# y_pred = model.predict(X_test)
# f1 = f1_score(Y_test, y_pred, average='macro')
# print(f"F1 分数: {f1}")

# import pandas as pd

```

```

# from sklearn.model_selection import train_test_split
# from sklearn.svm import SVC
# from sklearn.metrics import f1_score

# # 假设 data 是你的 DataFrame 数据
# # 假设 Y 是你的目标变量
# # 假设 feature_columns 是你选择的特征列

# # 选取特征变量
# X = data[feature_columns]

# # 划分训练集和测试集
# X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3,
random_state=42)

# # 创建支持向量机分类器模型
# model = SVC(random_state=42)

# # 训练模型
# model.fit(X_train, Y_train)

# # 计算 F1 分数
# y_pred = model.predict(X_test)
# f1 = f1_score(Y_test, y_pred, average='macro')
# print(f"F1 分数: {f1}")

Y_pred=model.predict(X_test)
# 计算评估指标
accuracy = accuracy_score(Y_test, Y_pred)
recall = recall_score(Y_test, Y_pred, average='macro') # 宏平均
f1 = f1_score(Y_test, Y_pred, average='macro') # 宏平均
cm = confusion_matrix(Y_test, Y_pred) # 混淆矩阵

# 输出评估指标
print(f'准确率: {accuracy:.4f}')
print(f'召回率: {recall:.4f}')
print(f'F1 分数: {f1:.4f}')
print('混淆矩阵:')
print(cm)
print('分类报告:')
print(classification_report(Y_test, Y_pred))

第二问:
#!/usr/bin/env python

```



```

# from sklearn.model_selection import train_test_split
# coding: utf-8
# from sklearn.svm import SVC
# from sklearn.metrics import f1_score
# In[6]:
## 假设 data 是你的 DataFrame 数据
## 假设 Y 是你的目标变量
## 假设 feature_columns 是你选择的特征列
import pandas as pd
import numpy as np
from scipy.optimize import curve_fit
# X = data[feature_columns]
def analyze_core_loss(data):
## 划分训练集和测试集
# X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3,
random_state=42)
参数:
## 创建支持向量机分类器模型
# model = SVC(random_state=42)
## 训练模型
# model.fit(X_train, Y_train)
返回:
## 计算 d1t 分数
# y_pred = model.predict(X_test)
# f1 = f1_score(Y_test, y_pred, average='macro')
# print(f"F1 分数: {f1}")
- mean_errors: 平均误差
Y_pred=model.predict(X_test)
# 计算评估指标 ln_k_data: 各温度对应的 ln(k) 值
accuracy = accuracy_score(Y_test, Y_pred)
recall = recall_score(Y_test, Y_pred, average='macro') # 宏平均
f1 = f1_score(Y_test, Y_pred, average='macro') # 宏平均
cm = confusion_matrix(Y_test, Y_pred) # 混淆矩阵
# 1. 计算最大值列
# 输出评估指标
print(f'准确率: {accuracy:.4f}')
print(f'召回率: {recall:.4f}')
print(f'F1 分数: {f1:.4f}')
print('混淆矩阵:')
print(cm)
# 3. 筛选正弦波数据
print(classification_report(Y_test, Y_pred))
data.rename(columns={'max_value': '峰值磁通密度'}, inplace=True)
第二问: data = data[['温度', '频率', '损耗功率', '峰值磁通密度']]
#!/usr/bin/env python
# 4. 全局参数拟合

```

```

def linear_model(X, ln_k, alpha, beta):
    ln_f, ln_Bm = X
    return ln_k + alpha * ln_f + beta * ln_Bm

ln_P = np.log(data['损耗功率'])
X_global = (np.log(data['频率']), np.log(data['峰值磁通密度']))

popt_global, _ = curve_fit(linear_model, X_global, ln_P, p0=[-10, 1.5,
2.5])
ln_k_global, alpha, beta = pop_t_global
k_global = np.exp(ln_k_global)

# 5. 温度相关参数拟合
temperatures = data['温度'].unique()
ln_k_list = []

for T in temperatures:
    mask = data['温度'] == T
    data_T = data[mask]

    def model_k(X, ln_k):
        return linear_model(X, ln_k, alpha, beta)

    X_T = (np.log(data_T['频率']), np.log(data_T['峰值磁通密度']))
    ln_P_T = np.log(data_T['损耗功率'])

    try:
        pop_t_T, _ = curve_fit(model_k, X_T, ln_P_T, p0=[ln_k_global])
        ln_k_list.append({'温度': T, 'ln_k': pop_t_T[0]})
    except RuntimeError:
        continue

ln_k_df = pd.DataFrame(ln_k_list)

# 6. 温度系数拟合
def ln_k_temp(T, ln_k0, gamma):
    return ln_k0 + gamma * T

popt_temp, _ = curve_fit(ln_k_temp, ln_k_df['温度'], ln_k_df['ln_k'],
p0=[ln_k_global, 0])
ln_k0, gamma = pop_t_temp
k0 = np.exp(ln_k0)

# 7. 计算预测值和误差

```

```

    data['P_pred_SE'] = k_global * data['频率']**alpha * data['峰值磁通密度']**beta
    data['k_T'] = k0 * np.exp(gamma * data['温度'])
    data['P_pred_Mod'] = data['k_T'] * data['频率']**alpha * data['峰值磁通密度']**beta

    data['误差_SE'] = np.abs(data['损耗功率'] - data['P_pred_SE']) / data['损耗功率'] * 100
    data['误差_Mod'] = np.abs(data['损耗功率'] - data['P_pred_Mod']) / data['损耗功率'] * 100

    return {
        'global_params': {
            'ln_k_global': ln_k_global,
            'k_global': k_global,
            'alpha': alpha,
            'beta': beta
        },
        'temp_params': {
            'ln_k0': ln_k0,
            'k0': k0,
            'gamma': gamma
        },
        'mean_errors': {
            'Steinmetz': data['误差_SE'].mean(),
            'Modified': data['误差_Mod'].mean()
        },
        'processed_data': data,
        'ln_k_data': ln_k_df
    }

```

In[3]:

使用示例

```

if __name__ == "__main__":
    # 读取原始数据
    data_1 = pd.read_excel('C 题附件.xlsx', sheet_name='材料 1')

    # 执行分析
    analysis_result = analyze_core_loss(data_1)

    # 输出结果

```

```
print("全局参数:", analysis_result['global_params'])
print("温度参数:", analysis_result['temp_params'])
print("平均误差:", analysis_result['mean_errors'])
print("处理后的数据前 5 行:\n", analysis_result['processed_data'].head())
```

In[4]:

使用示例

```
if __name__ == "__main__":
    # 读取原始数据
    data_2 = pd.read_excel('C 题附件.xlsx', sheet_name='材料 2')

    # 执行分析
    analysis_result = analyze_core_loss(data_2)

    # 输出结果
    print("全局参数:", analysis_result['global_params'])
    print("温度参数:", analysis_result['temp_params'])
    print("平均误差:", analysis_result['mean_errors'])
```

In[7]:

使用示例

```
if __name__ == "__main__":
    # 读取原始数据
    data_3 = pd.read_excel('C 题附件.xlsx', sheet_name='材料 3')

    # 执行分析
    analysis_result = analyze_core_loss(data_3)

    # 输出结果
    print("全局参数:", analysis_result['global_params'])
    print("温度参数:", analysis_result['temp_params'])
    print("平均误差:", analysis_result['mean_errors'])
```

使用示例

```

if __name__ == "__main__":
    # 读取原始数据
    data_4 = pd.read_excel('C 题附件.xlsx', sheet_name='材料 4')

    # 执行分析
    analysis_result = analyze_core_loss(data_4)

    # 输出结果
    print("全局参数:", analysis_result['global_params'])
    print("温度参数:", analysis_result['temp_params'])
    print("平均误差:", analysis_result['mean_errors'])

# In[16]:

import pandas as pd
from tabulate import tabulate

data = {
    "材料一": {
        'k_global': 0.073834, 'alpha': 1.718353, 'beta': 2.516920,
        'k0': 0.139488, 'gamma': -0.011537,
        '修正前误差': 29.633216, '修正后误差': 16.031030
    },
    "材料二": {
        'k_global': 0.073834, 'alpha': 1.718353, 'beta': 2.516920,
        'k0': 0.139488, 'gamma': -0.011537,
        '修正前误差': 33.679679, '修正后误差': 20.450686
    },
    "材料三": {
        'k_global': 0.298246, 'alpha': 1.613580, 'beta': 2.525366,
        'k0': 0.537449, 'gamma': -0.010527,
        '修正前误差': 30.932572, '修正后误差': 18.733647
    },
    "材料四": {
        'k_global': 0.416596, 'alpha': 1.596033, 'beta': 2.557349,
        'k0': 0.789113, 'gamma': -0.010841,
        '修正前误差': 28.775410, '修正后误差': 17.052106
    }
}

# 处理数据，保留三位小数并添加百分号

```

```

for material, values in data.items():
    for key, value in values.items():
        if key in ['修正前误差', '修正后误差']:
            data[material][key] = "{:.3f}%".format(value)
        else:
            data[material][key] = round(value, 3)

# 创建 DataFrame
df = pd.DataFrame(data).T.reset_index().rename(columns={'index': '材料'})

# 不同的表格样式
table_styles = ['github']
for style in table_styles:
    print(tabulate(df, headers='keys', tablefmt=style))
    print("\n")

```

第三问:

```

#!/usr/bin/env python
# coding: utf-8

# In[1]:

import pandas as pd
data=pd.read_csv('data.csv')

data

data=data[['损耗功率','磁芯材料','温度','电磁波形']]
data.columns=['损耗功率','磁芯材料','温度','电磁波形']
data

data['温度'].unique()

data_1=data.copy()

data_1.loc[:, '温度'] = data_1['温度'].astype(str) + '度'

data.to_csv('Q3_data.csv', index=None)

```

#具体分析详看代码视频讲解

```
import pandas as pd
data_3=pd.read_csv('Q3_data.csv')
```

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
```

定义数据

```
data = {
    '研究对象': [
        '磁芯材料', '电磁波形', '温度', '磁芯材料 * 电磁波形',
        '磁芯材料 * 温度', '电磁波形 * 温度', '磁芯材料 * 电磁波形 * 温度'
    ],
    '对损耗功率是否有显著性影响': [
        '是', '是', '是', '是', '否', '否', '否'
    ]
}
```

创建 DataFrame

```
df = pd.DataFrame(data)
```

设置图片清晰度

```
plt.rcParams['figure.dpi'] = 300
```

设置支持中文的字体

```
plt.rcParams['font.family'] = 'SimHei'
```

创建一个图形和轴

```
fig, ax = plt.subplots()
```

隐藏坐标轴

```
ax.axis('off')
```

创建表格

```
table = ax.table(cellText=df.values, colLabels=df.columns, loc='center',
cellLoc='center')
```

设置表格字体大小

```
table.set_fontsize(10)
```

设置表格单元格的宽度

```

for i in range(len(df.columns)):
    table.auto_set_column_width(i)

# 设置表头样式
for (row, col), cell in table.get_celld().items():
    if row == 0:
        cell.set_facecolor('#40466e')
        cell.set_text_props(color='w')

plt.show()

```

第四问: #!/usr/bin/env python
coding: utf-8

In[324]:

```

import pandas as pd

df=pd.read_excel('C 题附件.xlsx',sheet_name='材料 1')

df.head()

filtered_df = df[df['电磁波形'].isin(['梯形波'])]

# 创建新的表格
new_df = filtered_df.copy()

subset = new_df.iloc[:, 4:]

# 计算每行的最大值并形成新的一列
new_df['max_value'] = subset.max(axis=1)

frequencies = new_df.iloc[:, 1].values # 第 3 列 (索引 2) 为频率
B_data = df.iloc[:, 4:1028].values # 第 6-1029 列 (索引 5-1028) 为磁密数据

def calculate_equivalent_frequency(B, f):
    """
    计算等效频率 f_eq (MSE 方法)
    """

```


参数:

B : 一维数组, 1024 个磁通密度采样点 (单位: T)

f : 波形基频 (单位: Hz)

返回:

f_eq : 等效频率 (单位: Hz)

"""

校验输入

assert len(B) == 1024, "必须包含 1024 个采样点"

assert f > 0, "频率必须为正数"

计算周期 $T = 1/f$

$T = 1.0 / f$

$\Delta B = \max(B) - \min(B)$

生成等间距时间轴

$t = \text{np.linspace}(0, T, 1024)$

$dt = t[1] - t[0]$ # 时间间隔

计算 dB/dt (中心差分法)

$dBdt = \text{np.gradient}(B, dt, \text{edge_order}=2)$

计算积分 $\int (dB/dt)^2 dt$

$\text{integral} = \text{simps}(dBdt ** 2, t)$

等效频率公式

$f_{eq} = (1 / (\Delta B^2 * \pi^2)) * \text{integral}$

return f_eq

import numpy as np

import pandas as pd

from scipy.integrate import simps

equivalent_frequencies = []

for i in range(len(new_df)):

 B = B_data[i]

 f = frequencies[i]

跳过无效数据

if f <= 0 or np.isnan(B).any():

 equivalent_frequencies.append(np.nan)

 continue

feq = calculate_equivalent_frequency(B, f)

equivalent_frequencies.append(feq)

```

new_df['等效频率_Hz'] = equivalent_frequencies

new_df=new_df[['温度',          '频率',   '损耗功率', 'max_value',          '电磁波形',
', '等效频率_Hz']]

new_df.to_csv('Q4_1.csv', index=None)

import pandas as pd
import matplotlib.pyplot as plt

plt.figure(figsize=(10, 6))

# 绘制第一列数据
plt.plot(new_df["频率"], label="原始频率")

        # 绘制第二列数据
plt.plot(new_df["等效频率_Hz"], label="等效频率")

        # 设置图表标题
plt.title('初始频率与等效频率对比')
        # 设置 x 轴标签
plt.xlabel('数据索引')
        # 设置 y 轴标签
plt.ylabel('数值')

        # 显示图例
plt.legend()

        # 显示网格线
plt.grid(True)

        # 显示图表
plt.show()

# In[355]:

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

```

```

import seaborn as sns
from scipy.optimize import curve_fit
from mpl_toolkits.mplot3d import Axes3D
from matplotlib import cm

def linear_model(X, ln_k, alpha, beta):
    ln_f, ln_Bm, ln_fq = X
    return ln_fq + ln_k + alpha * ln_f + beta * ln_Bm

# 准备数据
ln_P = np.log(new_df['损耗功率'])
ln_f = np.log(new_df['等效频率_Hz'])
ln_fq = np.log(new_df['频率'])
ln_Bm = np.log(new_df['max_value'])
X = np.vstack((ln_f, ln_Bm, ln_fq))

# 全局拟合, 初始猜测值 [ln(k), alpha, beta]
# 这里将 ln_fq 作为额外的参数传入 curve_fit
popt, pcov = curve_fit(linear_model, X, ln_P, p0=[-10, 1.5, 2.5])

ln_k_global, alpha, beta = popt
k_global = np.exp(ln_k_global)

print("\n 拟合得到的全局参数: ")
print(f"ln(k_global) = {ln_k_global:.4f}")
print(f"k_global = {k_global:.4e}")
print(f"alpha = {alpha:.4f}")
print(f"beta = {beta:.4f}")

k_global = 6.4262e-02
alpha = 0.7260
beta = 2.4024

new_df['公式预测'] = k_global * new_df['等效频率_Hz']**alpha *
new_df['max_value']**beta*new_df['频率']

new_df['误差_Mod'] = np.abs(new_df['损耗功率'] - new_df['公式预测']) /
new_df['损耗功率'] * 100

```

```

mean_error_SE = new_df['误差_Mod'].mean()
print(mean_error_SE)

import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt
plt.rcParams.update({'font.size': 18})
plt.rcParams['font.sans-serif'] = ['SimHei'] # 设置中文字体为黑体
plt.rcParams['axes.unicode_minus'] = False # 解决负号显示问题
# 绘制预测值与实际值的对比图
plt.figure(figsize=(12, 6))
scatter = sns.scatterplot(x='损耗功率', y='公式预测', hue='温度', data=new_df,
palette='viridis')
line = sns.lineplot(x='损耗功率', y='损耗功率', data=new_df, color='red',
linestyle='--')

# 手动添加图例
handles, labels = scatter.get_legend_handles_labels()
line_handle = line.get_lines()[0]
plt.legend(handles + [line_handle], labels + ['理想预测'])

plt.xlabel('实际损耗功率')
plt.ylabel('公式预测')
plt.title('预测功率与实际值的对比')
plt.show()

new_df['误差_Mod'] = np.abs(new_df['损耗功率'] - new_df['P_pred_Mod']) /
new_df['损耗功率'] * 100

new_df['P_pred_Mod'] = k2*new_df['频率'] * new_df['等效频率_Hz']**(a2-1) *
new_df['max_value']**beta2

```